

Не забыть включить запись!





Правила вебинара



Активно участвуем



Задаем вопрос в чат или голосом



Off-topic обсуждаем в Slack #канал группы или #general



Вопросы вижу в чате, могу ответить не сразу



Преподаватель



Тюменцев Евгений

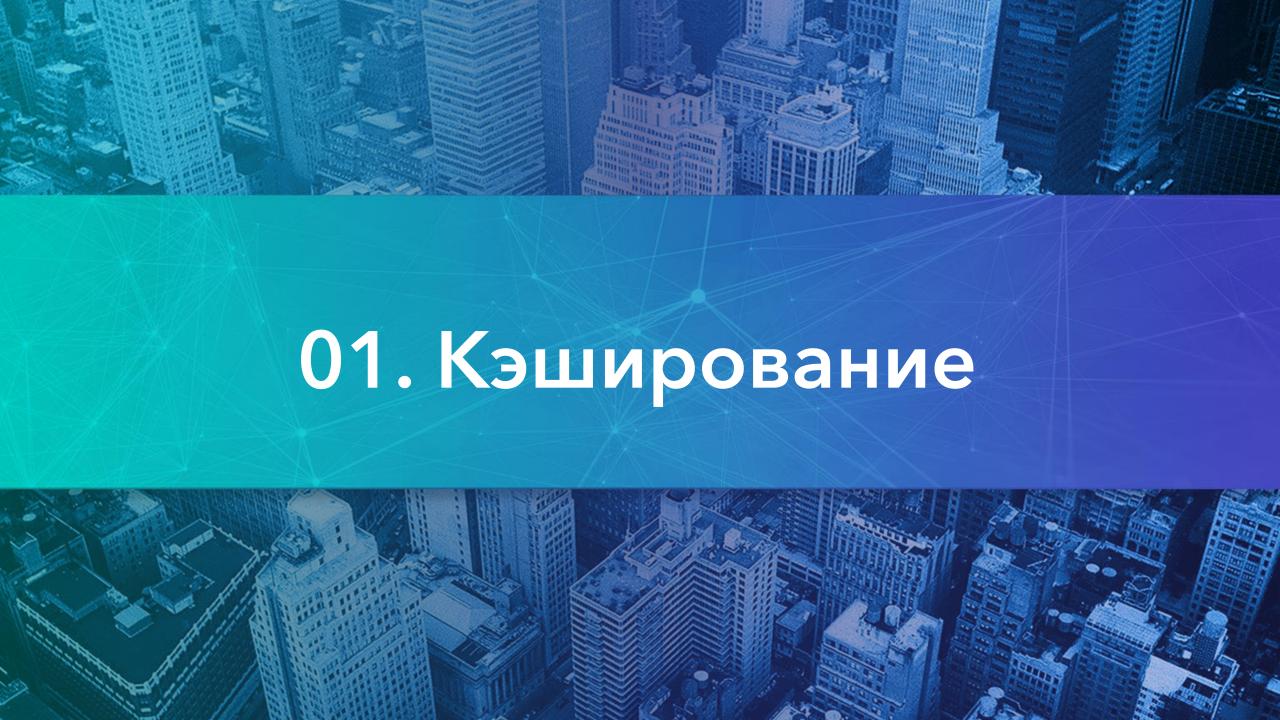
- 9 лет руковожу компаний по разработке ПО
- в прошлом занимался разработкой многопоточных кроссплатформенных приложений на C++, серверных приложений на C#
- 20 преподаю ООП, паттерны, C++, C#, Kotlin

Цели вебинара После занятия вы сможете

Использовать основные паттерны кэширования

Решать типичные проблемы, связанные с кэшированием

3 Выбирать инструмент кэширования под задачу



• Кэш - промежуточный буфер с более быстрым доступом, чем основное хранилище

- Кэш промежуточный буфер с более быстрым доступом, чем основное хранилище
- Кэширование способ оптимизации, использующий кэш

- Кэш промежуточный буфер с более быстрым доступом, чем основное хранилище
- Кэширование способ оптимизации, использующий кэш
- Почему не хранить всё в кэше?

- Кэш промежуточный буфер с более быстрым доступом, чем основное хранилище
- Кэширование способ оптимизации, использующий кэш
- Почему не хранить всё в кэше?
 - Дороже

- Кэш промежуточный буфер с более быстрым доступом, чем основное хранилище
- Кэширование способ оптимизации, использующий кэш
- Почему не хранить всё в кэше?
 - Дороже
 - Меньший объём данных

- Кэш промежуточный буфер с более быстрым доступом, чем основное хранилище
- Кэширование способ оптимизации, использующий кэш
- Почему не хранить всё в кэше?
 - Дороже
 - Меньший объём данных
 - Обычно «энергозависимый»

• В конкретные моменты времени используется лишь небольшое подмножество данных («активная зона»)

- В конкретные моменты времени используется лишь небольшое подмножество данных («активная зона»)
- Примеры:
 - Чаты последние собщения

- В конкретные моменты времени используется лишь небольшое подмножество данных («активная зона»)
- Примеры:
 - Чаты последние собщения
 - Сервис такси последние заказы

- В конкретные моменты времени используется лишь небольшое подмножество данных («активная зона»)
- Примеры:
 - Чаты последние собщения
 - Сервис такси последние заказы
- В СУБД активная зона «поднимается» в память

• Алгоритм Белади (идеальный, теоретический)

- Алгоритм Белади (идеальный, теоретический)
- Least Recently Used (LRU)

- Алгоритм Белади (идеальный, теоретический)
- Least Recently Used (LRU)
- Most Recently Used (MRU)

- Алгоритм Белади (идеальный, теоретический)
- Least Recently Used (LRU)
- Most Recently Used (MRU)
- Псевдо-LRU (PLRU)

- Алгоритм Белади (идеальный, теоретический)
- Least Recently Used (LRU)
- Most Recently Used (MRU)
- Псевдо-LRU (PLRU)
- Least Frequently Used (LFU)

- Алгоритм Белади (идеальный, теоретический)
- Least Recently Used (LRU)
- Most Recently Used (MRU)
- Псевдо-LRU (PLRU)
- Least Frequently Used (LFU)
- Adaptive Replacement (балансировка между LRU и LFU)

Максима

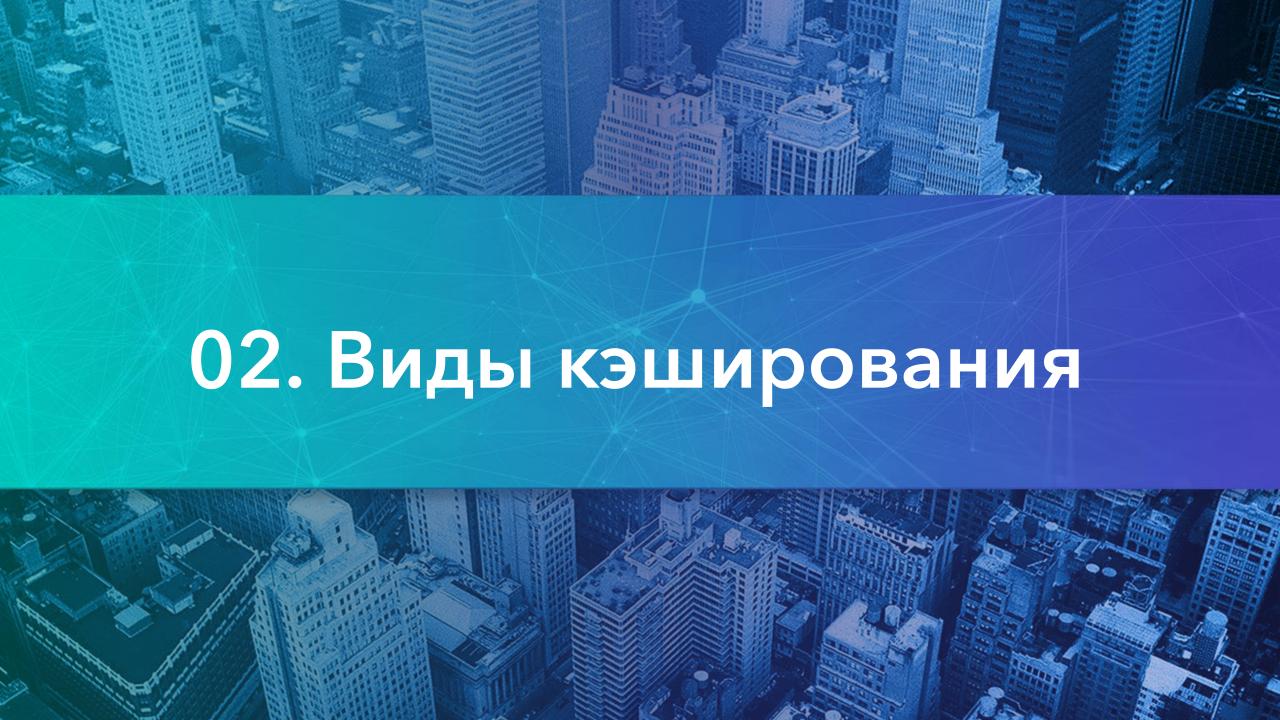
• Кэш не должен держать нагрузку

Максима

- Кэш не должен держать нагрузку
- Кэш нужен только для ускорения ответа

Максима

- Кэш не должен держать нагрузку
- Кэш нужен только для ускорения ответа
- Для проверки этого утверждения нужно проводить нагрузочное тестирование



• Результаты запросов к БД

- Результаты запросов к БД
- Ответы внешних сервисов

- Результаты запросов к БД
- Ответы внешних сервисов
- Динамически сгенерированные страницы

- Результаты запросов к БД
- Ответы внешних сервисов
- Динамически сгенерированные страницы
- Данные для обмена между сервисами

Классификация кэшей: по ценности данных

• Легко вычисляемые

Классификация кэшей: по ценности данных

- Легко вычисляемые
- Длительно вычисляемые

Классификация кэшей: по ценности данных

- Легко вычисляемые
- Длительно вычисляемые
- Невосстанавливаемые

Классификация кэшей: по типу доступа

• Локальный

Классификация кэшей: по типу доступа

- Локальный
- Приватный

Классификация кэшей: по типу доступа

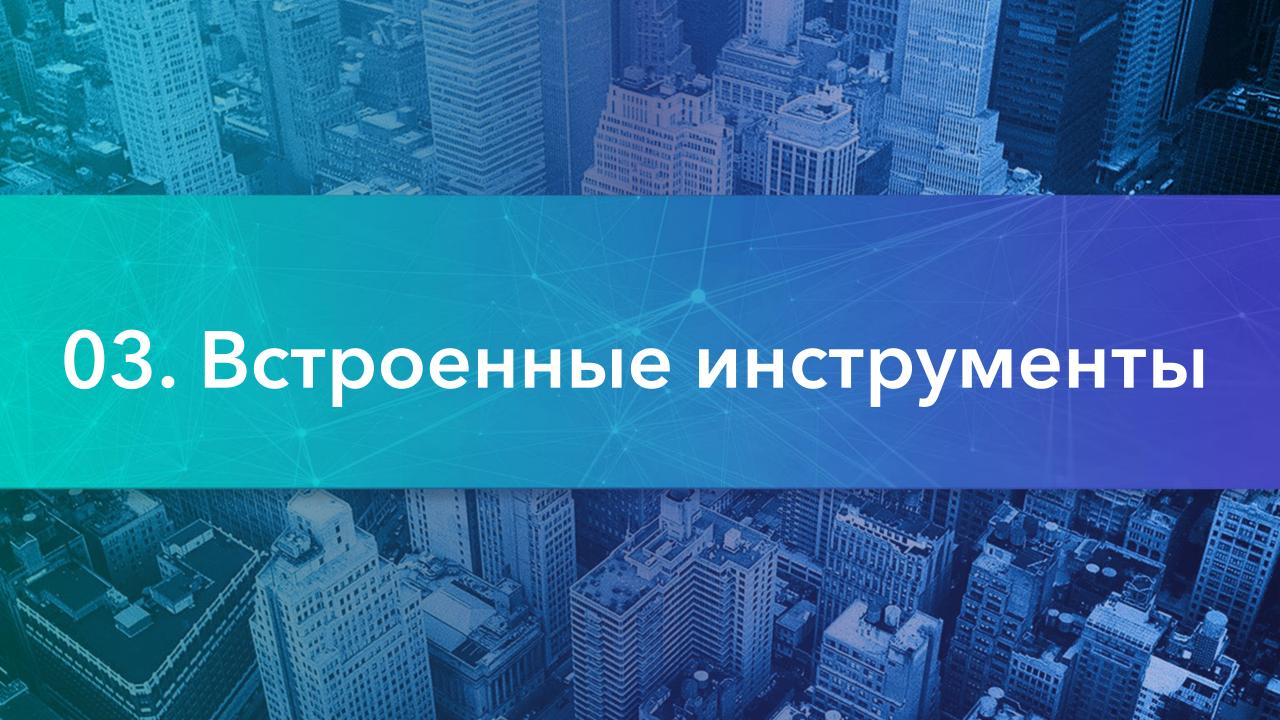
- Локальный
- Приватный
- Общий

• Вы разрабатываете веб-приложение. Когда нужно начинать думать о кэшировании?

- Вы разрабатываете веб-приложение. Когда нужно начинать думать о кэшировании?
- Где граница «легкой вычислимости» данных, когда уже требуется кэширование?

- Вы разрабатываете веб-приложение. Когда нужно начинать думать о кэшировании?
- Где граница «легкой вычислимости» данных, когда уже требуется кэширование?
- Какой основной минус кэширования?

- Вы разрабатываете веб-приложение. Когда нужно начинать думать о кэшировании?
- Где граница «легкой вычислимости» данных, когда уже требуется кэширование?
- Какой основной минус кэширования?
- Какие данные нельзя хранить в кэше? Почему?



• Кэшировать можем только GET (идемпотентный)

- Кэшировать можем только GET (идемпотентный)
- Информация о кэшировании передаётся в заголовках
 - ETAG

- Кэшировать можем только GET (идемпотентный)
- Информация о кэшировании передаётся в заголовках
 - ETAG
 - If-Modified-Since

- Кэшировать можем только GET (идемпотентный)
- Информация о кэшировании передаётся в заголовках
 - ETAG
 - If-Modified-Since
 - · Cache-Control

- Кэшировать можем только GET (идемпотентный)
- Информация о кэшировании передаётся в заголовках
 - ETAG
 - If-Modified-Since
 - Cache-Control
- LocalStorage

Кэширование в браузере - инвалидация

• Указывать версию в GET-параметрах

Кэширование в браузере - инвалидация

- Указывать версию в GET-параметрах
- Добавлять хэш (например, md5) в имена файлов

Кэширование в nginx

```
proxy cache path /data/nginx/cache keys zone=cache zone:10m;
map $request method $purge method {
    PURGE 1;
    default 0;
server {
    location / {
        proxy pass http://backend;
        proxy cache cache zone;
        proxy cache key $uri;
        proxy cache purge $purge method;
```

Кэширование на сервере

• Хранение данных в ОЗУ

Кэширование на сервере

- Хранение данных в ОЗУ
- Memcache

Кэширование на сервере

- Хранение данных в ОЗУ
- Memcache
- Redis



- Преимущества:
 - Многопоточная архитектура

- Преимущества:
 - Многопоточная архитектура
 - Производительность

- Преимущества:
 - Многопоточная архитектура
 - Производительность
- Недостатки:
 - Het persistence «из коробки»

- Преимущества:
 - Многопоточная архитектура
 - Производительность
- Недостатки:
 - Het persistence «из коробки»
 - Не поддерживает типизацию

- Преимущества:
 - Многопоточная архитектура
 - Производительность
- Недостатки:
 - Het persistence «из коробки»
 - Не поддерживает типизацию
 - Безопасность

• Внутри – хэш-таблица

- Внутри хэш-таблица
- Алгоритм вытеснения https://memcached.org/blog/modern-lru/

- Внутри хэш-таблица
- Алгоритм вытеснения https://memcached.org/blog/modern-lru/
- Основные операции: get, set, delete

- Внутри хэш-таблица
- Алгоритм вытеснения https://memcached.org/blog/modern-lru/
- Основные операции: get, set, delete
- Атомарные операции: incr, decr, append, prepend, cas, add



- Преимущества:
 - Поддерживает типизацию

- Преимущества:
 - Поддерживает типизацию
 - Поддерживает очереди и транзакции

- Преимущества:
 - Поддерживает типизацию
 - Поддерживает очереди и транзакции
 - Возможна master-slave репликация

- Преимущества:
 - Поддерживает типизацию
 - Поддерживает очереди и транзакции
 - Возможна master-slave репликация
 - Есть persistence «из коробки»

- Преимущества:
 - Поддерживает типизацию
 - Поддерживает очереди и транзакции
 - Возможна master-slave репликация
 - Есть persistence «из коробки»
- Недостатки:
 - Однопоточная архитектура



Tarantool: преимущества и недостатки

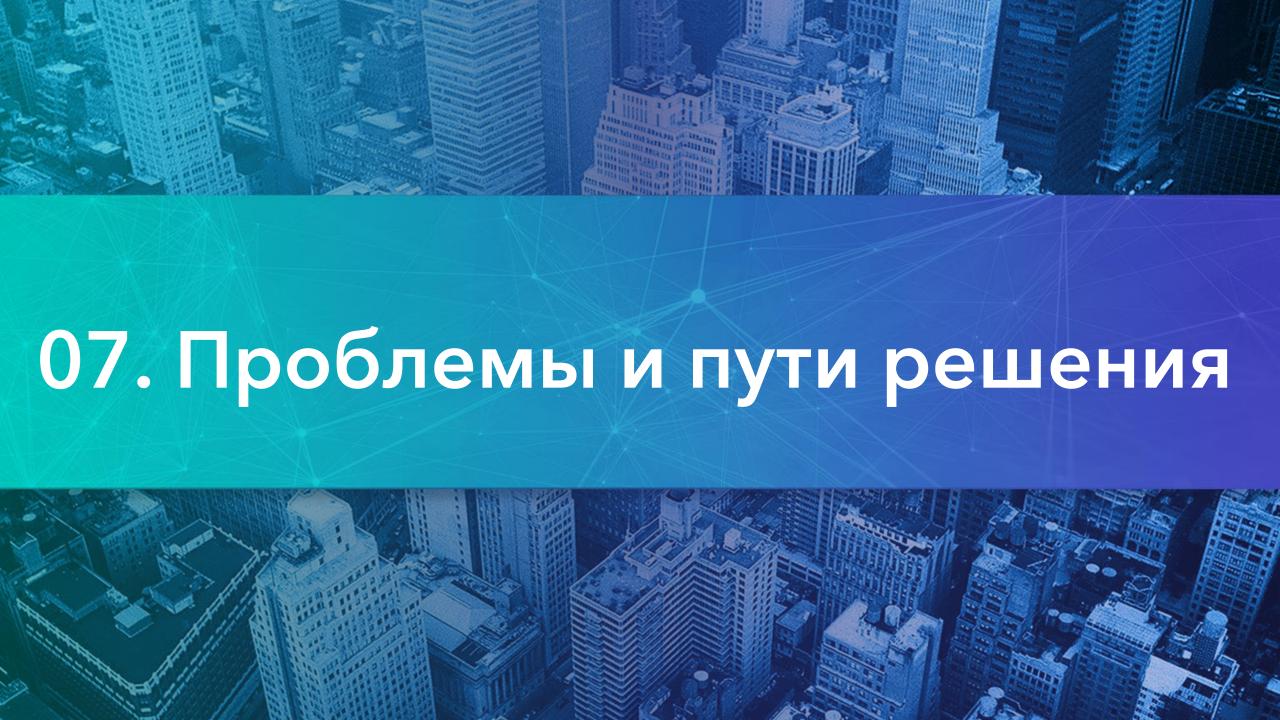
- Преимущества:
 - ACID, репликация, персистентность

- Преимущества:
 - ACID, репликация, персистентность
 - Хранимые процедуры на Lua

- Преимущества:
 - ACID, репликация, персистентность
 - Хранимые процедуры на Lua
 - Может реплицировать MySQL

- Преимущества:
 - ACID, репликация, персистентность
 - Хранимые процедуры на Lua
 - Может реплицировать MySQL
- Недостатки:
 - Дорогое хранение холодных данных

- Преимущества:
 - ACID, репликация, персистентность
 - Хранимые процедуры на Lua
 - Может реплицировать MySQL
- Недостатки:
 - Дорогое хранение холодных данных
 - Нет полной поддержки SQL



AverageTime = DbAccessTime * CacheMissRate + CacheAccessTime

AverageTime = DbAccessTime * CacheMissRate + CacheAccessTime

Пусть:

- DbAccessTime = 100ms
- CacheAccessTime = 20ms

AverageTime = DbAccessTime * CacheMissRate + CacheAccessTime

Пусть:

- DbAccessTime = 100ms
- CacheAccessTime = 20ms

Тогда при CacheMissRate > 0.8 получаем, что AverageTime > DbAccessTime

AverageTime = DbAccessTime * CacheMissRate + CacheAccessTime

Пусть:

- DbAccessTime = 100ms
- CacheAccessTime = 20ms

Тогда при CacheMissRate > 0.8 получаем, что AverageTime > DbAccessTime

Кэш замедляет среднее время ответа!

AverageTime = DbAccessTime * CacheMissRate + CacheAccessTime

Пусть:

- DbAccessTime = 100ms
- CacheAccessTime = 20ms

Тогда при CacheMissRate > 0.8 получаем, что AverageTime > DbAccessTime

Кэш замедляет среднее время ответа!

Вывод: минимальный CacheHitRate = CacheAccessTime / DbAccessTime

Кэширование тяжёлых запросов

Задача:

Есть тяжёлый запрос, который выполняется несколько секунд. Обращение к результатам запроса может быть сотни раз в минуту.

Хотим закэшировать данные с интервалом обновления, например, 1 час.

Крон недоступен.

Базовое решение

```
$result = $memcache->get('heavy_request');

if ($result !== false) {
   return $result;
}

$result = $someRepository->getSomeHeavyData();

$memcache->set('heavy_request', $result, 60 * 60);
```

Методика дублирования

```
$result = $memcache->get('heavy request');
if ($result !== false) {
  return $result;
// временно восстанавливаем ключ из копии
$copy = $memcache->get('heavy_request_copy');
$memcache->set('heavy request', $copy, 60 * 60);
$result = $someRepository->getSomeHeavyData();
$memcache->set('heavy request', $result, 60 * 60);
// дополнительно копируем значение с большим TTL
$memcache->set('heavy request_copy', $result, 60 * 60 + 30);
```

Вероятностное обновление

```
$result = $memcache->get('heavy request');
 // определяем необходимость обновления
$shouldExpire = $memcache->get('heavy request expiration');
$needUpdate = ($result === false)
                (time() + $delta * $beta * log(rand()) > $shouldExpire);
if (!$needUpdate) {
  return $result;
$result = $someRepository->getSomeHeavyData();
$memcache->set('heavy request', $result, 60*60);
// дополнительно сохраняем «момент экспирации» $memcache->set('heavy request expiration', time() + 60 * 60, 60 * 60);
```

• Оптимистичный подход

- Оптимистичный подход
 - Нужна дополнительная обработка неудачных попыток

- Оптимистичный подход
 - Нужна дополнительная обработка неудачных попыток
- Пессимистичный подход

- Оптимистичный подход
 - Нужна дополнительная обработка неудачных попыток
- Пессимистичный подход
 - Параллельная блокировка

- Оптимистичный подход
 - Нужна дополнительная обработка неудачных попыток
- Пессимистичный подход
 - Параллельная блокировка
 - «Вечная» блокировка

- Оптимистичный подход
 - Нужна дополнительная обработка неудачных попыток
- Пессимистичный подход
 - Параллельная блокировка
 - «Вечная» блокировка
 - Взаимная блокировка

Инвалидация кэша

• TTL

Инвалидация кэша

- TTL
- Прямая инвалидация
 - Очереди

Инвалидация кэша

- TTL
- Прямая инвалидация
 - Очереди
 - Тэги



• Алгоритмы определения сервера

- Алгоритмы определения сервера
 - Хеширование по модулю

- Алгоритмы определения сервера
 - Хеширование по модулю
 - Согласованное хеширование

- Алгоритмы определения сервера
 - Хеширование по модулю
 - Согласованное хеширование
- Холодный старт

- Алгоритмы определения сервера
 - Хеширование по модулю
 - Согласованное хеширование
- Холодный старт
 - Плавный запуск пользователей

- Алгоритмы определения сервера
 - Хеширование по модулю
 - Согласованное хеширование
- Холодный старт
 - Плавный запуск пользователей
 - «Прогрев» со случайным TTL

- Алгоритмы определения сервера
 - Хеширование по модулю
 - Согласованное хеширование
- Холодный старт
 - Плавный запуск пользователей
 - «Прогрев» со случайным TTL
- «Горячие» ключи

Консистентное хэширование

